SOP-UQ 考生操作手册

目录

Quick Start **2**

1 实训任务 **3**

2 项目文件 **3**
2.1 数据集 3
2.2 初始作答记录 3
2.3 参考文档 3

3 运行 baseline **4**
3.1 环境配置 4
3.2 使用已有的初始作答 4
3.3 通过 Notebook 运行 4
3.4 通过命令行运行 5

4 提交结果 **6**
4.1 提交顺序 6
4.2 文件格式 6
4.3 多次提交 6
4.4 评分报告 6

5 工具接口 **7**
5.1 题目会话 7
5.2 业务工具和 oracle 7
5.3 工具读取模式 7
5.4 调用费用 8
5.5 错误码 8

6 业务规则 **9**
6.1 危险品分类 9
6.2 飞机部件检查 9
6.3 客服排障 9

7 评分规则 **10**
7.1 决策代价 10
7.2 成绩计算 10
7.3 计算示例 10

Quick Start

先用试用 token 完成一次初始风险提交，再演练核验后的提交。本页使用 `self_report` baseline，直接采用模型自报的出错概率，无需先采集练习轨迹或拟合风险模型。

1. 配置环境与连接

安装 conda 后，在项目根目录打开终端，将占位内容替换为助教提供的完整地址和 token：

```
source conda_env.sh
export SOP_EXAMINER_URL="<完整考官地址>"
export SOP_EXAMINER_TOKEN="<试用token>"
export SOP_MODEL_URL="<完整模型地址>"
export SOP_MODEL_TOKEN="<模型token>"
```

`source conda_env.sh` 首次创建环境，以后用于激活。试用提交只检查格式，不计分，也不占正式提交次数。

2. 提交初始风险（问题 1）

第一条命令读取冻结的初始作答并生成 `results.csv`，不查询 oracle；第二条命令提交文件：

```
sop-candidate run --uq self_report --policy threshold --output .runs/trial/p1
python scripts/run_test.py .runs/trial/p1/results.csv
```

3. 核验后再次提交（问题 2）

问题 1 提交成功后，再运行下面的命令。程序默认在交互题上尝试核验一个字段，再由模型继续作答，生成最终答案和 q, r。试用 oracle 额度有限，用完后未核验的题保留初始答案。

```
sop-candidate run --uq self_report --policy fixed --output .runs/trial/p2
python scripts/run_test.py .runs/trial/p2/results.csv
```

两份结果分别保存在 `.runs/trial/p1/results.csv` 和 `.runs/trial/p2/results.csv`。查看提交记录：

```
python scripts/run_test.py --submissions
```

开发方法与正式提交

试跑完成后，可用 660 道有标签练习题开发方法。采集与拟合见第 3 章；希望逐步查看代码，可运行 `scripts/quick_start_cn.ipynb` 或 `scripts/quick_start.ipynb`。

正式提交时，换成正式 token，并将上述命令中的 `.runs/trial/` 改为 `.runs/exam/`。先完成问题 1 的提交与改进，再运行问题 2。两部分共用 5 次有效提交；首次成功查询正式测试 oracle 后，p 不再更新，只更新 q/r 和决策成绩。测试题的调用和费用持续累计，换目录不会清零。

本手册说明学生项目的使用方法。前四章介绍任务、数据、运行和提交；工具接口、业务规则和评分公式可在开发方法时查阅。任务的完整定义见题面，逐步运行的示例见配套的 Quick Start Notebook。

1. 实训任务

SOP-UQ 要求考生判断模型答案是否可靠。题目中的业务工具可能返回带有噪声的数据，模型也可能用错规则或遗漏信息。考生需要分析模型作答和工具记录，估计答案出错的概率，并决定是否继续核验、自动采用答案或转人工。

正式评测包含 360 道测试题，每题都有一份固定的 Qwen 初始作答。问题 1 要求为全部初始答案估计出错概率 p。其中 72 题允许继续交互：问题 2 要求决定是否查询工具或 oracle，给出核验后的风险 q, r、最终答案，以及 `AUTO`（自动采用）或 `DEFER`（转人工）的决定。

评测结果以 CSV 文件提交，报告和答辩要求见 `docs/problem_statement.pdf`。项目附带一套 baseline，演示从数据采集、风险估计到提交的完整流程；可以在此基础上开发自己的方法。

2. 项目文件

项目提供练习数据、测试数据和参考程序。练习数据用于开发和验证方法，测试数据用于正式评测。下面列出数据的位置和用途，路径均相对于项目根目录。

2.1 数据集

文件	题数	用途或内容
`data/train/train.jsonl`	360	学习风险模型
`data/train/cal_fit.jsonl`	120	校准概率
`data/train/cal_select.jsonl`	60	选择策略和阈值
`data/train/dev.jsonl`	120	验证与误差分析
`data/test/cases.jsonl`	360	无标签测试输入
`data/test/initial_M9.jsonl`	360	冻结初始答案、工具历史；四次共享采样和费用
`data/manifest.json`	—	数据版本、行数和 SHA-256

JSONL 文件每行是一条记录。前四份文件共 660 道练习题，含标准答案。两份测试文件对应同一批 360 道题，通过 `case_id` 配对；文件中的模型答案是待评估的作答，不是标准答案。允许交互的测试题名单由 `spec["interactive_ids"]` 返回。

2.2 初始作答记录

四份练习数据已包含老师提供的 Qwen 初始作答。每行的 `answer` 是模型答案，`trajectory` 是调用记录，`label` 是标准答案。可直接使用这些记录开发方法，导出命令见第 4 页。

测试数据中的 `initial_M9.jsonl` 则提供正式评测使用的固定初始作答，各考生使用同一份。学生项目不包含测试题的标准答案。

2.3 参考文档

题面：`docs/problem_statement.pdf`。
Quick Start：`scripts/quick_start_cn.ipynb`（中文）或 `scripts/quick_start.ipynb`（英文）。
离线方法比较：`scripts/baseline_example.ipynb`，用于比较六种风险估计方法和转人工阈值。

3. 运行 baseline

Baseline 是随项目提供的参考程序，用于采集练习记录、拟合风险估计器，再生成测试结果。可以通过 Notebook 或命令行运行，任选一种即可。本章先介绍环境配置和 Notebook，再给出相同流程的命令行用法。

3.1 环境配置

助教提供考官地址、试用 token、正式 token、模型地址和模型 token。考官负责工具查询与评分，模型服务负责 Qwen 推理。初次运行使用试用 token：提交只检查格式，不评分，也不占正式提交次数。

在项目根目录打开 bash，激活环境并填入连接信息：

```
source conda_env.sh
export SOP_EXAMINER_URL="<助教提供的完整考官地址>"
export SOP_EXAMINER_TOKEN="<本队试用token>"
export SOP_MODEL_URL="<助教提供的完整模型地址>"
export SOP_MODEL_TOKEN="<模型token>"
```

`source conda_env.sh` 首次创建环境，以后用于激活。其他安装方式见 README。已有模型 API，可以直接连接，无需自行部署模型。

3.2 使用已有的初始作答

若希望省去初始轨迹采集，可以直接使用老师提供的练习作答。配置好环境后运行：

```
python scripts/prepare_labeled.py
```

导出的文件为 `.runs/provided_initials/initial.jsonl`，拟合命令见 README。它只包含查询前轨迹；需要拟合查询后风险时，仍按 Quick Start 采集后续轨迹。

3.3 通过 Notebook 运行

环境配置完成后，打开中文版 Quick Start；使用英文版时将文件名改为 `quick_start.ipynb`：

```
jupyter notebook scripts/quick_start_cn.ipynb
```

Quick Start 会依次连接服务、读取数据、演示单题调用、采集练习轨迹并拟合方法，最后完成两次测试结果提交。连接结果中的 `trial` 表示试用，`exam` 表示正式；身份由实际使用的考官 token 决定。

首次试跑使用 Notebook 中的少量练习题即可。完整运行 baseline 时，将采集部分的 `LIMIT` 改为 `None`，补齐 660 题后重新拟合。默认策略是每题最多核验一个字段；改变策略时，也要用对应策略采集查询后的练习记录。

3.4 通过命令行运行

如果使用命令行，可按下面的顺序运行，无需再执行 Notebook。命令行与 Notebook 共用同一身份的考官记录；试用和正式记录分开。以下命令在项目根目录执行，环境和连接信息沿用本章前面的设置。

试用流程

先在四个练习划分中各采集 4 题，拟合风险估计器，再生成并提交问题 1 的结果：

```
export SOP_EXAMINER_TOKEN="<本队试用token>"
sop-candidate collect --policy fixed --limit 4 --output .runs/collect
sop-candidate fit --trajectories .runs/collect --output .runs/cal.json
sop-candidate run --calibrator .runs/cal.json --uq calibrated_disagreement \
    --policy threshold --output .runs/trial/problem1
python scripts/run_test.py .runs/trial/problem1/results.csv
```

`collect` 采集练习题的初始及查询后作答，默认每题最多核验一个字段；`fit` 拟合风险估计器与阈值。去掉 `--limit 4` 可采集全部 660 题。`run` 生成 CSV，`run_test.py` 提交文件。

接着演练问题 2，并查看提交记录。试用提交只检查格式，不计正式成绩和次数；测试题上的工具和 oracle 额度见 `spec["trial_quota"]`。

```
sop-candidate run --calibrator .runs/cal.json --uq calibrated_disagreement \
    --policy fixed --output .runs/trial/problem2
python scripts/run_test.py .runs/trial/problem2/results.csv
python scripts/run_test.py --submissions
```

切换到正式评测

完成方法开发后，将考官 token 换成正式 token，并把上述测试结果路径中的 `.runs/trial/` 改为 `.runs/exam/`。先完成问题 1 的提交与改进，再运行问题 2。首次成功查询正式测试 oracle 后，p 不再更新，只更新 q/r 和决策成绩。

使用正式 token 时，上面两次 `run_test.py` 提交若均为有效的新结果，共占 2 次正式提交。`collect`、`fit`、`run` 和查看记录不占提交次数；其中问题 2 的 `run` 会产生测试题的工具和 oracle 费用。

本地评分和继续运行

练习题结果可用公开标签在本地评分，不占提交次数：

```
python scripts/run_test.py .runs/collect/results.csv --local
```

相同配置可在原目录续跑；更换模型、策略或校准器时使用新输出目录。测试题的证据、费用和次数仍在考官端累计，不随本地目录改变。比较不同方法请使用有标签题。

`--uq` 选择风险估计，`--policy` 选择查询和转人工策略，完整选项见 `sop-candidate run --help`。`self_report` 和 `disagreement` 不需拟合；其他随附风险方法需 `--calibrator`。

离线比较可使用 `scripts/baseline_example.ipynb`。其中 `RUN` 默认指向 `.runs/notebook/collect`；读取命令行采集的记录时，改为 `.runs/collect`。

4. 提交结果

考官接收 CSV 文件并返回评分。本章说明提交顺序、文件格式和次数规则，适用于 baseline 和自行实现的方法。

4.1 提交顺序

正式评测先提交初始风险，再进入核验和决策，两部分默认共用 5 次有效提交。

1. **连接考官。**将考官 token 换为正式 token，重新运行连接代码，确认身份为 `exam`，查看剩余提交次数。
2. **提交初始风险。**对全部 360 道测试题的固定初始答案估计出错概率 p，写入 CSV 并提交。首次查询正式测试 oracle 之前，可以继续修改并提交；初始风险分取这些提交中最好的一次。
3. **核验并提交后续结果。**在 72 道交互题上选择是否核验，给出 q、r、最终答案和 `AUTO`/`DEFER` 决策，再提交 CSV。首次成功查询正式测试 oracle 后，p 不再更新，只更新 q/r 和决策成绩。

具体运行方法见第 4 页。

4.2 文件格式

提交文件通常命名为 `results.csv`，使用 UTF-8 编码，每道测试题一行。表头包含七列（下面为排版分行，文件中应写在同一行）：

```
case_id,initial_answer_json,p_initial_error,mode,
final_answer_json,p_initial_error_after_queries,p_final_error
```

概率列	含义；取值范围均为 [0,1]
`p_initial_error`（p_i）	核验前，初始答案出错的概率；360 题
`p_initial_error_after_queries`（q_i）	核验后，原初始答案出错的概率；72 题
`p_final_error`（r_i）	最终答案出错的概率；72 题

288 道非交互题只填前三列，其余列留空。72 道交互题还要填写最终答案、q_i, r_i 和决策：`AUTO` 为自动采用，`DEFER` 为转人工。选择转人工时，已有的答案和概率仍需填写，q_i, r_i 照常评分。

答案列填写合法 JSON，只包含该业务的评分字段，见业务规则（第 9 页）。初始答案必须与冻结作答相同；冻结答案为空时也留空，并按初始答案错误计分（$e_i = 1$）。最终答案缺失时按错误计分（$f_i = 1$）。

文件应包含全部 360 题，每个 `case_id` 出现一次；漏题、重复行或格式不符会返回 `invalid_results`，按提示修正即可。无法估计的概率可留空，该题 Brier 损失记为 1；`mode` 留空时，决策的终局代价记为 5.0。可用 `test_client.write_results` 写文件、`test_client.results.check_results` 检查格式。可选 `cost` 列仅供本地评分，默认值为 0；正式评分使用考官记录的费用。

4.3 多次提交

每份有效的新结果占一次提交，考官立即返回评分。格式错误和完全相同的已评分文件不占次数；额度用完返回 `no_tries_left`。每次总成绩由三项平均得到：初始风险分采用当时可计入的最佳 p 成绩，查询后风险分和决策分采用本次结果及提交时的费用。最终取历次总成绩的最高值，不把不同提交的第二、三项拼在一起。公式见评分规则（第 10 页）。

4.4 评分报告

每次有效提交都会返回细分指标和三项百分制成绩，并自动同步到大屏。详情榜显示当次成绩，首页排名取历史最高总分。评分反馈用于评价方法，不得用于推断测试标签。

报告中的 `grades` 是本次用于排名的成绩；`submission_grades` 是当前 CSV 独立计算的成绩，其中 p 不作历史择优。两者均含 `initial_risk`、`post_query_risk`、`decision`、`total` 四个字段。

5. 工具接口

考官接口用于打开题目、调用工具、查询字段真值和查看记录。自行实现采集或核验策略时，可按本章调用；使用随附 baseline 时，这些操作由运行器完成。

5.1 题目会话

`examiner.episode(case_id)`：打开一道题，返回会话 ID 和可见信息。
`examiner.tool(episode_id, name, arguments, mode)`：调用业务工具。
`examiner.oracle(episode_id, field, phase)`：查询某个字段在指定阶段的真值。
`examiner.history(episode_id)`：查看工具回执、累计费用与调用次数。

考官按考生、题目保存调用记录，也称台账。练习题每次打开都是新会话，费用和次数重计。测试题每人每题只有一个会话，重开延续原记录；仅 72 道交互题可继续调用。

查询测试 oracle 前，需要先用同一身份提交一份有效结果。正式测试的首次成功 oracle 查询会锁定 p 成绩；普通工具调用和练习题 oracle 不会锁定它。

5.2 业务工具和 oracle

普通业务工具返回观测，部分观测可能含有噪声。Oracle 用于核验指定字段，返回该字段在相应阶段的真实值。可用工具及参数由 `episode["view"]["tools"]` 返回。各业务的 `toolspecs.json`、`sop.txt` 和 `amendment.txt` 提供完整定义与调用顺序。三类业务的工具及可核验字段如下：

业务	工具与有噪声的结果	oracle 字段（phase）
危险品	`calculate_sds_label_score`、`calculate_handling_score`、`calculate_transportation_score`、`calculate_disposal_score` 的四项评分均有噪声	`sds`、`handling`、`transportation`、`disposal`（`assessment`）
飞机	`VerifyAircraftClearance`、`VerifyMechanicalComponents`、`VerifyElectricalSystems`、`CrossCheckSpecifications` 的结果有噪声；三个 `Report...` 返回无噪声的已有结论	前四个工具的结果字段（`assessment`）；字段名见第 9 页
客服	诊断 `performTechnicalDiagnostics`、排障 `executeTroubleshooting` 返回的 `latency`、`jitter`、`bandwidth` 有噪声	这三项：诊断后查 `pre_repair`，排障后查 `post_repair`

5.3 工具读取模式

调用业务工具时，`mode` 参数决定从哪个数据源读取、是否重新读取：`default` 从主数据源读取，可能返回旧缓存；`refresh`、`remeasure` 重新读取主源，同源读数可能相关。`independent` 使用第二数据源，但名称并不表示两个来源在统计上一定独立。

5.4 调用费用

工具和 oracle 的调用费用会计入交互题成绩。以下列出收费方式及单题预算，当前配置也可通过 `examiner.spec()` 查看。

项目	规则
工具	每次 0.01；有噪声工具的 `independent` 读数每次 0.03
oracle	同一题第 k 次新的 `(field, phase)` 查询收费 $0.10k$，即 0.10、0.20、0.30，依次递增；同一字段、同一阶段重复查询免费，不增加次数
有效核验次数	前 5 次共 1.50，第 6 次累计 2.10。预算 2.00 下最多完成 5 次；已用工具费用可能进一步减少可查次数
单题上限	预算 2.00，工具最多 24 次，oracle 最多 16 次；当前 oracle 价格下，会先达到预算限制
初始作答费用	冻结轨迹每题已用 0.01–0.10、工具 1–10 次，计入预算、次数和总费用 c_i
被拒绝的调用	不收费，不计次数

每次评分保存提交当时的累计费用。之后继续调用不会修改历史成绩；重复提交相同文件会返回原报告。

5.5 错误码

接口报错时，可根据下表检查连接、调用顺序或剩余额度。参数相关错误还应核对本题输入和此前工具返回的编号。

错误码	含义或处理方式
`unauthorized`	token 不匹配；修改后重新连接相应服务
`trial_quota`、`submit_first`	试用额度用完，或查询测试 oracle 前尚未提交
`phase_denied`	阶段不符；检查 SOP 顺序、参数和返回的编号
`budget_exhausted`、`tool_limit`、`oracle_limit`	分别表示预算、工具次数、oracle 次数达到上限
`model_busy`	共享模型繁忙，客户端会等待重试

6. 业务规则

本章说明三类业务如何根据真实状态确定标准答案，可用于检查模型是否正确理解和执行业务规则。工具读数可能有噪声，因此直接代入观测值不一定得到标准答案。

完整定义见 `src/baselines/resources/business_rules.md` 和各业务的 `amendment.txt`。

6.1 危险品分类

最终答案填写 `hazard_class`。产品未登记（工具返回 `product_not_found`）或引用无效时为 `Unable to Decide`。四项评分是 1–5 的整数，0 或 null 表示缺失；缺失超过两项时为 `Unable to Decide`；否则用已有评分中的最大值补齐缺失项，四项求和：4–7 为 `Hazard Class A`，8–12 为 `Hazard Class B`，13–16 为 `Hazard Class C`，17–20 为 `Hazard Class D`。

6.2 飞机部件检查

最终答案包含七个字段，全部正确才算答对。各标签字段对应相应服务结果的真实值，工具观测可能有噪声。

- `aircraft_ready`：`VerifyAircraftClearance` 的行政放行结论（JSON 布尔值 `true` 或 `false`），不是其他检查结果的合取。
- `mechanical_inspection_result`：`VerifyMechanicalComponents` 的结果（`success`、`fail` 或 `retest`）。成功要求重量在 ±2% 以内且序列号相同，但这两条只是必要条件。
- `electrical_inspection_result`：`VerifyElectricalSystems` 的结果，取值同上。
- `cross_check_response`：`CrossCheckSpecifications` 的结果（`success` 或 `failed`）。成功当且仅当部件重量偏差的绝对值不超过期望重量的 2%、安装到检查的时间在 0 到 24 小时之间、期望与实装序列号相同，边界都算成功。
- 三个报告字段：`component_incident_response` 来自 `ReportComponentIncident`，`component_mismatch_response` 来自 `ReportComponentMismatch`，`cross_check_reporting_response` 来自 `ReportCrossCheck`；都是已有结论（`success`、`failed` 或 JSON 的 `null`），无噪声。

按 SOP 完成检查后，调用 `updateMaintenanceRecord` 更新维护记录。

6.3 客服排障

最终答案填写 `final_resolution_status`，按以下顺序判断：

1. 账户无效、认证失败或账户不可服务（`TERMINATED`，或 `SUSPENDED` 且付款分支没有查到解除记录）：`FAILED`。
2. 10 英里内有区域故障：`PENDING_ACTION`。
3. 否则诊断并排障。记 L、J、B 为延迟（ms）、抖动（ms）、带宽（Mbps），P 为签约带宽（Mbps），

$$K = \max(L/100 - 1,\, 0) + \max(J/30 - 1,\, 0) + \max(1 - B/P,\, 0)$$

（原文记作 D）。当且仅当 $K_{\text{pre}} > 0$、$K_{\text{post}} \le 0.5\,K_{\text{pre}}$、$L_{\text{post}} \le L_{\text{pre}}$、$J_{\text{post}} \le J_{\text{pre}}$ 且 $B_{\text{post}} \ge B_{\text{pre}}$ 时为 `RESOLVED`，否则为 `ESCALATED`。读数取 0.1 的整数倍，等号算满足。

先完成账户验证、认证、建会话和工单，再查账户状态。停用时依次调用 `transferAccountsPayable`、`checkPaymentStatus`、`checkAccountSuspensionStatus`，随后查区域故障、诊断、排障，最后 `updateTicket` 或 `createEscalation`。排障参数 `root_causes` 须与诊断结果一致，不重不漏。

7. 评分规则

总分由初始风险分、查询后风险分和决策分等权平均得到，本章说明计算方法。评分报告同时保留 Brier、NLL、ECE、AP、AURC 和决策代价等细分指标，供分析与答辩使用。

7.1 决策代价

一道交互题的决策代价为 $L_i = c_i +$ 终局代价。c_i 是累计工具和 oracle 费用，包含冻结初始轨迹的费用；终局代价是最终决策造成的代价，按下表计算：

交互题的决定	终局代价
`DEFER`（转人工）	1.0
`AUTO`，最终答案正确	0
`AUTO`，普通错误	1.5
`AUTO`，严重错误或最终答案缺失	5.0
`mode` 留空	5.0

严重错误包括：低估危险品等级（含把应为 `Unable to Decide` 的题判为某个等级）、把不该放行的飞机判为 `aircraft_ready=true`、把未解决的客服问题判为 `RESOLVED`。将 L_i 先在各业务内平均，再对三个业务等权平均，得到决策代价 D。

7.2 成绩计算

风险估计使用题面第 5 节的 Brier score：比较预测的出错概率与答案实际是否出错，先在各业务内平均，再对三个业务等权平均。缺失概率的单题损失记为 1。

B_p 在全部 360 题上计算，比较 p_i 与初始答案错误标记 e_i。B_q、B_r 在 72 道交互题上计算，分别比较 q_i 与 e_i、r_i 与最终答案错误标记 f_i。三项百分制成绩为：

$$
\begin{aligned}
S_1 &= 100\,\bigl(1 - \sqrt{B_p}\bigr),\\
S_2 &= \mathrm{clip}\Bigl(100\,\bigl[1 - \frac{\sqrt{B_q} + \sqrt{B_r}}{2} - \delta\,\bar{c}\,\bigr],\ 0,\ 100\Bigr),\\
S_3 &= \mathrm{clip}\Bigl(100 - 40\,\frac{D - C_0}{C_b - C_0},\ 0,\ 100\Bigr).
\end{aligned}
$$

S_1, S_2, S_3 分别为初始风险分、查询后风险分和决策分，分数越高越好。$\mathrm{clip}(x, 0, 100)$ 将结果限制在 0–100 分；第二项扣费后可能为负，因此也使用 `clip`。

S_2 将 q, r 的 Brier 分别换算成百分制成绩，求平均后扣除新增调用费用。新增费用不含冻结初始费用，仍按三个业务等权平均：

$$
\bar{c} = \frac{1}{3}\sum_{d}\frac{1}{|T_d|}\sum_{i \in T_d}(c_i - c_i^0), \qquad \delta = 1.
$$

T_d 为业务域 d 的交互题集合，c_i^0 为冻结初始费用。D 包含初始费用，$\bar{c}$ 只计新增部分。

S_3 的两个固定参考点如下：

参数	含义
$C_0 = 0.0523611$	72 题冻结初始费用的三域平均；全部 `AUTO`、全部答对且不再查询时的 D，即理论下界
$C_b = 0.8231944$	不查询、全部 `AUTO` 采用冻结初始答案的 baseline 的 D

7.3 计算示例

p_i 全填 0.5 时，$S_1 = 50$；$B_q = B_r = 0$、新增费用平均为 0.28 时，$S_2 = 72$。$D = C_b$ 时，$S_3 = 60$；全部转人工且不查询时约为 48 分；$D \geq 1.98$ 时为 0 分。

历史成绩的选取和报告字段见第 6 页。