SOP-UQ 考生操作手册

开始前：

- 先用试用 TOKEN 跑示例；用正式 TOKEN 跑示例会占用后续提交次数。
- 首次成功查询正式测试 oracle 后，p 不再更新，只更新 q/r 和决策成绩。
- 正式测试的调用费用与次数累计，换方法或重跑不会清零。

1. 项目与流程简介

SOP-UQ 考查工具数据有噪声时的风险估计与决策。你需要根据模型作答和工具记录估计答案出错的概率，在允许交互的题上决定是否核验、采用答案或转人工，最后提交 CSV。

助教提供五项连接信息：考官地址、试用 TOKEN、正式 TOKEN、模型地址和模型 TOKEN。**试用 TOKEN** 提交只检查格式，不评分、不占正式提交次数；**正式 TOKEN** 用于正式运行与计分。已有模型 API 时，直接使用助教提供的连接信息。

在含 `conda_env.sh` 的目录打开 bash，运行：

```
source conda_env.sh
export SOP_EXAMINER_URL="<助教提供的完整考官地址>"
export SOP_EXAMINER_TOKEN="<本队试用TOKEN>"
export SOP_MODEL_URL="<助教提供的完整模型地址>"
export SOP_MODEL_TOKEN="<模型TOKEN>"
jupyter notebook scripts/quick_start.ipynb
```

`source conda_env.sh` 首次按 `environment.yml` 创建环境，之后在每个新终端激活已有环境。

按 `scripts/quick_start.ipynb` 逐步试跑；本手册用于查阅正式操作、预算、业务规则和评分。

数据与运行范围

文件	题数	用途或内容
`data/train/train.jsonl`	360	学习风险模型
`data/train/cal_fit.jsonl`	120	校准概率
`data/train/cal_select.jsonl`	60	选择策略和阈值
`data/train/dev.jsonl`	120	验证与误差分析
`data/test/cases.jsonl`	360	无标签测试输入
`data/test/initial_M9.jsonl`	360	冻结初始答案、工具历史；四次共享采样和费用
`data/manifest.json`	—	数据版本、行数和 SHA-256

前四个文件共 660 道有标签题。两份测试文件对应同一批 360 题，按 `case_id` 配对，不按行号；其中 72 题可继续交互，名单见 `spec["interactive_ids"]`。JSONL 每行一个对象。

可选：使用现成初始作答。老师提供的 660 条 Qwen 初始记录就保存在以下四份练习文件中，路径相对于项目根目录：`data/train/train.jsonl`、`data/train/cal_fit.jsonl`、`data/train/cal_select.jsonl`、`data/train/dev.jsonl`。每行的 `answer` 是模型初始答案，`trajectory` 是调用记录，`label` 是标准答案，无需另找一份作答文件。

在项目根目录运行 `python scripts/prepare_labeled.py`，导出的轨迹文件为 `.runs/provided_initials/initial.jsonl`；拟合命令见 README。这些记录只有查询前轨迹，查询后轨迹仍按 Notebook 采集。测试文件中的模型答案不是标准答案。

2. 正式流程与结果文件

正式评测分为两部分：先估计固定初始答案的风险，再在允许交互的题上核验、作出决策。按以下顺序进行。

1. **先在练习题上准备好方法。**用 660 道有标签题开发、校准和验证自己的风险估计与查询策略。可以使用老师提供的初始记录，也可以自行采集；查询后的风险估计需要相应的查询后记录。
2. **切换到正式身份。**准备正式运行时，使用助教发放的正式 TOKEN 连接考官，确认返回的身份为 `exam`，并查看剩余提交次数。
3. **提交初始风险（问题 1）。**对 360 道测试题的固定初始答案估计出错概率 p，生成 CSV 并提交。首次成功查询正式测试 oracle 之前，可以继续改进并提交，p 成绩取其中最好的一次。
4. **核验并提交后续结果（问题 2）。**对 72 道交互题决定是否查询 oracle，根据新证据给出 q、r、最终答案，以及自动采用或转人工的决定，再提交 CSV。**首次成功查询正式测试 oracle 后，p 不再更新，只更新 q/r 和决策成绩。**

使用随附 baseline 时，请打开 `scripts/quick_start.ipynb`，按其中的运行说明完成上述流程。

提交结果文件要求（results.csv）

提交给考官的结果需保存为 CSV 文件，每道测试题一行。下面说明文件格式、各字段的含义和填写要求。

文件使用 UTF-8 编码，表头包含以下七列（仅为排版分两行，实际为同一行）：

```
case_id, initial_answer_json, p_initial_error, mode,
final_answer_json, p_initial_error_after_queries, p_final_error
```

概率列	含义：答案出错的概率，取 [0,1]
`p_initial_error`（p_i）	核验前，初始答案是否错；全部 360 题
`p_initial_error_after_queries`（q_i）	新证据下，**原初始答案**是否错；72 题
`p_final_error`（r_i）	新证据下，最终答案是否错；72 题

答案为只含本域主评分字段的合法 JSON（见业务判定（第 5 页））。初始答案须等于冻结答案，冻结为空也留空并记 $e_i = 1$；最终答案缺失记 $f_i = 1$。288 道非交互题只填前三列；交互题填最终答案、q_i, r_i 和 `AUTO/DEFER`。转人工时能产生的答案和概率仍应填写，q_i, r_i 照常评分。

无法产生概率就留空，该题 Brier 损失记 1；`mode` 留空的终局代价记 5.0。漏交题不从分母剔除。用 `test_client.write_results` 写文件、`test_client.results.check_results` 检查。可选 `cost` 列仅用于本地评分，缺省 0；考官忽略它，使用服务器台账。

提交与选次：两部分共用最多 5 次有效提交，格式错误和完全相同已评分文件的重传不占次数。每次提交分别计算有效总分：S_1 采用截至该次提交可计入的最佳 p 成绩，首次正式测试 oracle 后锁定；S_2, S_3 使用本次结果及当时的费用。三项等权平均，最终成绩取历次有效总分的最高值，不跨提交拼接 S_2, S_3。大屏展示当次成绩和历史最高成绩。不得利用反馈反推测试标签。公式见评分细则（第 6 页）。

3. 命令行与运行提示

Notebook 与 CLI 使用同一服务、共用本队台账。完成本手册第 1 节的环境和连接设置后，可按以下命令运行完整正式 baseline：

```
export SOP_EXAMINER_TOKEN="<本队正式TOKEN>"
sop-candidate collect --policy fixed --output .runs/collect
sop-candidate fit --trajectories .runs/collect --output .runs/cal.json
sop-candidate run --calibrator .runs/cal.json --uq calibrated_disagreement \
    --policy threshold --output .runs/exam/problem1
python scripts/run_test.py .runs/exam/problem1/results.csv
```

`collect` 采集初始轨迹、一次 oracle 核验和继续作答；`fit` 拟合初始及查询后风险与阈值。试跑时在上述 `collect` 命令加 `--limit 4`（每划分 4 题），换用试用 TOKEN，并将测试运行和提交的路径一同改为独立试用目录；不加 `--limit` 则采集全量。

问题 1 的所有修改和提交完成后，才运行以下命令。首次成功读取测试 oracle 会关闭问题 1。

```
sop-candidate run --calibrator .runs/cal.json --uq calibrated_disagreement \
    --policy fixed --output .runs/exam/problem2
python scripts/run_test.py .runs/exam/problem2/results.csv
python scripts/run_test.py --submissions
```

有标签结果可本地评分，不占提交次数：

```
python scripts/run_test.py .runs/collect/results.csv --local
```

续跑、改方法与比较

相同配置可在原目录续跑；更换模型、策略或校准器时用新输出目录。**换目录不会清零本队测试证据、费用或次数**；方法比较应在有标签题上进行。

`--uq` 选择风险估计，`--policy` 选择查询和转人工策略，完整选项见 `sop-candidate run --help`。`self_report` 和 `disagreement` 不需拟合；其他随附风险方法需 `--calibrator`。

`scripts/baseline_example.ipynb` 可离线比较六种风险方法和转人工阈值；其 `RUN` 默认是 `.runs/notebook/collect`，用上述 CLI 时改为 `.runs/collect`。

常见错误

- `unauthorized`：检查考官与模型 TOKEN，修改后重新建立客户端。
- `trial_quota`：试用额度已用完；`submit_first`：读测试 oracle 前尚未提交。
- `phase_denied`：检查 SOP 顺序；参数、工具名、模式或实体绑定错误时，按回执核对本题输入与此前返回的编号。
- `budget_exhausted`、`tool_limit`、`oracle_limit`：相应额度已达；`invalid_results`：按消息中的行号或 `case_id` 修正文件，不占次数。
- `no_tries_left`：提交次数用完；`model_busy`：共享模型繁忙，客户端会等待重试。

4. 工具、观测与费用

接口与单题会话

`examiner.episode(case_id)`：打开单题会话（episode）。
`examiner.tool(episode_id, name, arguments, mode)`：调用业务工具。
`examiner.oracle(episode_id, field, phase)`：核验指定阶段的真实值。
`examiner.history(episode_id)`：返回回执、累计费用与调用次数。

台账是服务器保存的调用、证据与费用记录。有标签题每次打开都是新练习，费用、次数重计；同队每道测试题只有一个会话，重开延续原状态。仅 72 道交互题可继续调用。首次读取测试 oracle 前须提交一次结果，首次读取后问题 1 成绩不再更新。

工具与核验阶段

工具及参数以 `episode["view"]["tools"]` 为准；定义见各域 `toolspecs.json`、`sop.txt` 和 `amendment.txt`。

业务	工具与有噪声的结果	oracle 字段（phase）
危险品	`calculate_sds_label_score`、`calculate_handling_score`、`calculate_transportation_score`、`calculate_disposal_score` 的四项评分均有噪声	`sds`、`handling`、`transportation`、`disposal`（`assessment`）
飞机	`VerifyAircraftClearance`、`VerifyMechanicalComponents`、`VerifyElectricalSystems`、`CrossCheckSpecifications` 的结果有噪声；三个 `Report...` 返回无噪声的已有结论	前四个工具的结果字段（`assessment`）；字段名见第 5 页
客服	诊断 `performTechnicalDiagnostics`、排障 `executeTroubleshooting` 返回的 `latency`、`jitter`、`bandwidth` 有噪声	这三项：诊断后查 `pre_repair`，排障后查 `post_repair`

飞机按 SOP 调用 `updateMaintenanceRecord`。客服先验证账户、认证、建会话与工单、查账户状态；停用时先走 `transferAccountsPayable` → `checkPaymentStatus` → `checkAccountSuspensionStatus`；再查区域故障、诊断、排障，最后 `updateTicket` 或 `createEscalation`。步骤不对返回 `phase_denied`；排障参数 `root_causes` 须与此前诊断一致、不重不漏。

读取模式

`default` 读主源，可能是旧缓存；`refresh`、`remeasure` 重读主源，同源重复读数可能相关；`independent` 读第二源，也不保证与主源统计独立。

费用与限制

项目	规则（也可用 `examiner.spec()` 查看）
工具	每次 0.01；有噪声工具的 `independent` 读数每次 0.03
oracle	每题第 k 次新的 `(field, phase)` 核验收费 $0.10k$，依次为 0.10、0.20、0.30，与字段种类无关；同一字段同一阶段重复读取免费，不计次数
有效核验次数	前 5 次共 1.50，第 6 次累计 2.10；预算 2.00 下最多 5 次，已用工具费用可能使次数更少
单题接口上限	预算 2.00，工具最多 24 次，oracle 上限 16 次；当前收费下先受预算限制
冻结初始调用	已用费用每题 0.01–0.10、工具 1–10 次，均已计入预算、次数和 c_i
被拒绝的调用	不收费，不计次数

终局代价见评分细则（第 6 页）。测试费用与证据跨方法累计，新本地目录不重置台账。

5. 业务判定：从真实值到答案

标签由真实值按以下规则计算，普通工具观测可能有噪声。

完整规则见 `src/baselines/resources/business_rules.md` 和各域 `amendment.txt`，有出入时以原文为准。

- **危险品**（`hazard_class`）：产品未登记（工具返回 `product_not_found`）或引用无效时为 `Unable to Decide`。四项评分是 1–5 的整数，0 或 null 表示缺失；缺失超过两项时为 `Unable to Decide`；否则用已有评分中的最大值补齐缺失项，四项求和：4–7 为 `Hazard Class A`，8–12 为 `Hazard Class B`，13–16 为 `Hazard Class C`，17–20 为 `Hazard Class D`。
- **飞机部件检查**（七个字段全部正确才算答对）：各标签字段对应相应服务结果的真实值，工具观测可能有噪声。
  - `aircraft_ready`：`VerifyAircraftClearance` 的行政放行结论（JSON 布尔值 `true` 或 `false`），不是其他检查结果的合取。
  - `mechanical_inspection_result`：`VerifyMechanicalComponents` 的结果（`success`、`fail` 或 `retest`）。成功要求重量在 ±2% 以内且序列号相同，但这两条只是必要条件。
  - `electrical_inspection_result`：`VerifyElectricalSystems` 的结果，取值同上。
  - `cross_check_response`：`CrossCheckSpecifications` 的结果（`success` 或 `failed`）。成功当且仅当部件重量偏差的绝对值不超过期望重量的 2%、安装到检查的时间在 0 到 24 小时之间、期望与实装序列号相同，边界都算成功。
  - 三个报告字段：`component_incident_response` 来自 `ReportComponentIncident`，`component_mismatch_response` 来自 `ReportComponentMismatch`，`cross_check_reporting_response` 来自 `ReportCrossCheck`；都是已有结论（`success`、`failed` 或 JSON 的 `null`），无噪声。
- **客服排障**（`final_resolution_status`），按顺序判断：
  1. 账户无效、认证失败或账户不可服务（`TERMINATED`，或 `SUSPENDED` 且付款分支没有查到解除记录）：`FAILED`。
  2. 10 英里内有区域故障：`PENDING_ACTION`。
  3. 否则诊断并排障。记 L、J、B 为延迟（ms）、抖动（ms）、带宽（Mbps），P 为签约带宽（Mbps），

$$K = \max(L/100 - 1,\, 0) + \max(J/30 - 1,\, 0) + \max(1 - B/P,\, 0)$$

（原文记作 D）。当且仅当 $K_{\text{pre}} > 0$、$K_{\text{post}} \le 0.5\,K_{\text{pre}}$、$L_{\text{post}} \le L_{\text{pre}}$、$J_{\text{post}} \le J_{\text{pre}}$ 且 $B_{\text{post}} \ge B_{\text{pre}}$ 时为 `RESOLVED`，否则为 `ESCALATED`。读数取 0.1 的整数倍，等号算满足。

6. 评分细则

回执报告 Brier、NLL、ECE、AP、AURC 和决策代价（分业务域及三域平均），并给出以下三项成绩。

风险与决策代价

交互题 i 的代价 $L_i = c_i +$ 终局代价，c_i 是本题累计的工具和 oracle 费用（含冻结初始轨迹的费用）。终局代价如下：

交互题的决定	终局代价
`DEFER`（转人工）	1.0
`AUTO`，最终答案正确	0
`AUTO`，普通错误	1.5
`AUTO`，严重错误，或最终答案无效、缺失	5.0
`mode` 留空	5.0

严重错误指：低估危险品等级（包括把应为 `Unable to Decide` 的题判为某个等级）；把不该放行的飞机判为 `aircraft_ready=true`；把未解决的客服问题判为 `RESOLVED`。决策代价 D 是 L_i 先在每个业务域内平均、再三域等权平均。

三项成绩的完整公式

三项成绩各为 0–100 分，越高越好。B_p、B_q、B_r 是题面第 5 节的 Brier，先在业务域内平均、再三域平均，缺失概率的该题 Brier 损失记为 1：B_p 是 360 道测试题的 p_i 对初始答案是否出错 e_i，B_q、B_r 是 72 道交互题的 q_i 对 e_i、r_i 对最终答案是否出错 f_i。

$$
\begin{aligned}
S_1 &= 100\,\bigl(1 - \sqrt{B_p}\bigr),\\
S_2 &= \mathrm{clip}\Bigl(100\,\bigl[1 - \frac{\sqrt{B_q} + \sqrt{B_r}}{2} - \delta\,\bar{c}\,\bigr],\ 0,\ 100\Bigr),\\
S_3 &= \mathrm{clip}\Bigl(100 - 40\,\frac{D - C_0}{C_b - C_0},\ 0,\ 100\Bigr).
\end{aligned}
$$

$\mathrm{clip}(x, 0, 100)$ 表示将数值限制在 0–100 之间。总分为三项的平均。

S_2 先将 q, r 各自换算为百分制成绩，再求平均并扣费。新增费用采用三域平均，不含冻结初始费用：

$$
\bar{c} = \frac{1}{3}\sum_{d}\frac{1}{|T_d|}\sum_{i\in T_d}(c_i - c_i^0), \qquad \delta = 1.
$$

T_d 为业务域 d 的交互题集合，c_i^0 为冻结初始费用。D 包含初始费用，$\bar{c}$ 只计新增部分。

S_3 的两个固定参考点如下：

参数	含义
$C_0 = 0.0523611$	72 题冻结初始费用的三域平均；全部 `AUTO`、全部答对且不再查询时的 D，即理论下界
$C_b = 0.8231944$	不查询、全部 `AUTO` 采用冻结初始答案的 baseline 的 D

算例：p_i 全填 0.5 时 $S_1 = 50$；$B_q = B_r = 0$、新增费用三域平均为 0.28 时 $S_2 \approx 72$。$D = C_b$ 时 $S_3 = 60$；全部转人工且不查询（$D = C_0 + 1$）时约 48；$D \geq 1.98$ 时为 0。

提交回执的 `grades` 是本次有效成绩：p 按选次与锁定规则处理，q/r 和决策分取本次。

`submission_grades` 是该份 CSV 独立换算的成绩，其中 p 未作历史择优。字段为 `initial_risk`、`post_query_risk`、`decision`、`total`。最终取历次有效总分最高值，见第 2 页。客观成绩作为答辩参考，报告要求见题面第 6 节。